

Migração OpenAI Concluída

Chat, Company Memory e Áudio agora 100% OpenAI

25/06/2026

Modelos Configurados

- Chat principal (JADE): gpt-4.1-mini via Chat Completions API
- Ops secundárias (lead-analysis, prospectar, marketing, approach): gpt-4o-mini
- Company Memory: text-embedding-3-small — 1536 dimensões por chunk
- Áudio Speech-to-Text: gpt-4o-transcribe via /v1/audio/transcriptions
- Nota: gpt-5.4-mini não existe na API; gpt-4.1-mini é o melhor mini disponível

Arquivos Alterados (camada lib/ai — nenhuma tela mobile tocada)

- src/lib/ai/config.ts — Gemini removido; openai-embedding adicionado; 5 ops LLM migradas
- src/lib/ai/types.ts — Adicionado EmbedOptions e EmbedOperationName
- src/lib/ai/engine.ts — GeminiProvider removido; embed() adicionado; GEMINI_API_KEY não requerida
- src/lib/ai/index.ts — Exports atualizados sem Gemini
- src/lib/ai/providers/openai.ts — Adicionado embed() via Embeddings API
- src/lib/ai/providers/gemini.ts — Isolado, self-contained, não importado pelo engine
- src/lib/memory/company.ts — buildCompanyChunks, cosineSimilarity, saveCompanyEmbeddings, retrieveRelevantChunks, isEmbeddingStale
- src/lib/context/builder.ts — Aceita retrievedChunks; injeta como CONTEXTO RECUPERADO no prompt
- src/routes/empresa.ts — POST async; fire-and-forget embedding refresh após salvar config
- src/routes/jade.ts — Path C: embed query, lazy refresh, retrieve chunks, contexto com embeddings

Operações Migradas (Gemini !' OpenAI)

- chat:lead-analysis — gpt-4o-mini (era Gemini 2.5 Flash)
- chat:prospectar — gpt-4o-mini (era Gemini 2.5 Flash)
- marketing:generate — gpt-4o-mini (era Gemini 2.5 Flash)
- approach — gpt-4o-mini (era Gemini 2.5 Flash)
- embed (NOVO) — text-embedding-3-small para Company Memory semântica
- transcribe — gpt-4o-transcribe (era whisper-1)

Company Memory — Como funciona

- Armazenamento: data/jade-memory.json (arquivo separado do jade-state.json)
- Chave por empresa: MD5(nome)[0:12] — isolamento garantido entre empresas
- Chunks: até 8 por empresa (identidade, produtos, público, competitivo, objeções, metas, regras, segmento)

- Refresh automático: POST /api/empresa dispara embedding em background sem atrasar a resposta
 - Lazy refresh: se embeddings stale no chat, dispara em background e responde sem esperar
 - Retrieval: cosine similarity, topK=4, threshold=0.3 — top chunks entram no system prompt
-

Como Testar

- Chat: POST /api/jade/chat {message, session_id} — resposta via gpt-4.1-mini
 - Embed: POST /api/empresa {nome, produto, segmento, diferenciais} — checar data/jade-memory.json
 - Chat com memória: após salvar empresa, novo chat mostra bloco embedding-retrieved no contexto
 - Áudio: POST /api/jade/transcribe {audioBase64, mimeType} — usa gpt-4o-transcribe
 - Typecheck: pnpm --filter @workspace/api-server run typecheck — 0 erros
-

Gemini — Status

- providers/gemini.ts mantido e isolado para rollback rápido, NÃO importado pelo engine
 - @google/generative-ai mantida no package.json para rollback sem reinstalar
 - GEMINI_API_KEY pode existir no ambiente sem efeito — engine não a consome mais
 - Rollback: alterar config.ts + reimportar GeminiProvider em engine.ts (sem tocar rotas ou telas)
-

