

JADE AI Engine — Camada Central de IA

Abstração de provedor, retry, logs e configuração por operação

24 de junho de 2026

Objetivo

Criar uma camada intermediária de IA que abstraia o provedor atual (Gemini) e prepare a migração futura para OpenAI, sem alterar nenhum comportamento visível: rotas públicas, respostas da API, design do app mobile e funcionalidade do Whisper permanecem idênticos.

Estrutura criada — lib/ai/

- types.ts — interfaces compartilhadas: ChatOptions, GenerateOptions, TranscribeOptions, OperationName, NormalizedMessage.
- config.ts — registro central de modelo, temperatura e maxOutputTokens por operação (chat, chat:lead-analysis, chat:prospectar, marketing:generate, approach, transcribe).
- providers/gemini.ts — GeminiProvider: encapsula GoogleGenerativeAI; métodos chat() e generate() sem lógica de negócio.
- providers/whisper.ts — WhisperProvider: encapsula a chamada raw fetch para OpenAI Whisper; parâmetros vindos do config.
- engine.ts — JadeAIEngine singleton: orquestra providers, normaliza roles (user/assistant !' user/ model para Gemini), aplica retry em erros transientes (5xx, 429, timeout), loga duração de cada operação.
- index.ts — re-exporta engine, tipos e config para acesso centralizado.

Rotas migradas

- /jade/chat (Path C normal) !' engine.chat() com operation='chat'.
- /jade/chat (análise de leads Path A e B) !' engine.generate() com operation='chat:lead-analysis'.
- /jade/prospectar !' engine.generate() com operation='chat:prospectar'.
- /jade/approach !' engine.generate() com operation='approach'.
- /jade/transcribe !' engine.transcribe() (Whisper via WhisperProvider).
- /marketing/generate !' engine.generate() com operation='marketing:generate'.

Funcionalidades centralizadas no Engine

- Seleção de modelo por operação (único ponto de configuração em config.ts).
- Temperatura e maxOutputTokens configurados por operação, não por handler.
- Normalização de roles: 'assistant' !' 'model' para Gemini; firstUserIdx filter preservado.
- Retry automático em erros 5xx, 429 e timeout (1 retry após 1.5s).
- Log de duração (ms) e tamanho da resposta (chars) para cada operação via logger pino.
- Providers instanciados uma única vez (singleton) — não mais por request.

Preparação para migração futura

Para trocar Gemini por OpenAI no chat basta: (1) criar providers/openai.ts implementando os mesmos métodos chat() e generate(); (2) ajustar engine.ts para usar o novo provider; (3) alterar config.ts para apontar para os modelos OpenAI. Nenhuma rota ou tela precisa ser tocada.

Validação

- Typecheck do api-server: zero erros.
 - API reiniciada com sucesso.
 - Teste POST /api/jade/chat com {'messages':[{'role':'user','content':'oi, tudo bem?'}]} retornou {'message':'Me conta.','handoff':false}.
 - Comportamento idêntico ao anterior — mesma experiência para o usuário.
-

